[Octobre 1950

VOL. LIX. NON. 236.]

# **ESPRIT**

# UN BILAN TRIMESTRIEL

DE

# PSYCHOLOGIE ET PHILOSOPHIE



# I.—MACHINES INFORMATIQUES ET INTELLIGENCE

# PAR AM TURING

# 1. Le jeu des imitations.

JE PROPOSE d'examiner la question : « Les machines peuvent-elles penser ? Cela devrait commencer par des définitions de la signification des termes «ÿmachineÿ» et «ÿpenserÿ». Les définitions pourraient être rédigées de manière à refléter autant que possible l'usage normal des mots, mais cette attitude est dangereuse. Si la signification des mots «ÿmachineÿ» et «ÿpenserÿ» doit être trouvée en examinant comment ils sont couramment utilisés, il est difficile d'échapper à la conclusion que la signification et la réponse à la questionÿ: «ÿLes machines peuvent-elles penserÿ?ÿ» est à rechercher dans une enquête statistique comme un sondage Gallup. Mais c'est absurde. Au lieu de tenter une telle définition, je remplacerai la question par une autre, qui lui est étroitement liée et qui s'exprime en termes relativement non ambigus.

La nouvelle forme du problème peut être décrite en termes de jeu que nous appelons le "jeu d'imitation". Il se joue avec trois personnes, un homme (A), une femme (B) et un interrogateur (C) qui peuvent être des deux sexes. L'interrogateur reste dans une pièce à l'écart des deux autres. Le but du jeu pour l'interrogateur est de déterminer lequel des deux autres est l'homme et lequel est la femme. Il les connaît par les étiquettes X et Y, et à la fin du jeu, il dit soit «ÿX est A et Y est Bÿ», soit «ÿX est B et Y est Aÿ». L'interrogateur est autorisé à poser des questions à A et B ainsiÿ:

Cÿ: Est-ce que X peut me dire la longueur de ses cheveuxÿ?

Supposons maintenant que X soit réellement A, alors A doit répondre. C'est le but de A dans le jeu d'essayer d'amener C à faire une mauvaise identification. Sa réponse pourrait donc être

"Mes cheveux sont en bardeaux et les mèches les plus longues mesurent environ neuf pouces de long."

Afin que les tons de voix n'aident pas l'interrogateur, les réponses doivent être écrites ou, mieux encore, dactylographiées. L'arrangement idéal est d'avoir un téléimprimeur communiquant entre les deux salles. Alternativement, la question et les réponses peuvent être répétées par un intermédiaire. Le but du jeu pour le troisième joueur (B) est d'aider l'interrogateur. La meilleure stratégie pour elle est probablement de donner des réponses véridiques. Elle peut ajouter des choses telles que "Je suis la femme, ne l'écoutez pas!" à ses réponses, mais cela ne servira à rien car l'homme peut faire des remarques similaires.

Nous posons maintenant la question : « Que se passera-t-il lorsqu'une machine jouera le rôle de A dans ce jeu ? L'interrogateur décidera-t-il aussi souvent à tort lorsque le jeu se joue ainsi que lorsqu'il se joue entre un homme et une femme ? Ces questions remplacent notre question d'origine, « Les machines peuvent-elles penser ?

# Critique du nouveau problème.

En plus de demander : « Quelle est la réponse à cette nouvelle forme de question », on peut demander : « Cette nouvelle question mérite-t-elle d'être étudiée ? Cette dernière question, nous l'étudions sans plus tarder, coupant ainsi court à une régression infinie.

Le nouveau problème a l'avantage de tracer une ligne assez nette entre les capacités physiques et intellectuelles d'un homme. Aucun ingénieur ou chimiste ne prétend être capable de produire un matériau qui ne se distingue pas de la peau humaine. Il est possible que cela soit fait à un moment donné, mais même en supposant que cette invention soit disponible, nous devrions penser qu'il n'y a pas grand intérêt à essayer de rendre une "machine à penser" plus humaine en l'habillant d'une telle chair artificielle. La forme sous laquelle nous avons posé le problème reflète ce fait dans la condition qui empêche l'interrogateur de voir ou de toucher les autres concurrents, ou d'entendre leurs voix.

Certains autres avantages du critère proposé peuvent être mis en évidence par des exemples de questions et de réponses. Ainsi:

Q : S'il vous plaît, écrivez-moi un sonnet sur le sujet du pont du Forth.

A : Comptez sur moi pour celui-ci. Je n'ai jamais pu écrire de poésie.

Q: Ajouter 34957 à 70764

A: (Faites une pause d'environ 30 secondes puis donnez comme réponse) 105621.

Q: Jouez-vous aux échecs?

R : Oui.

Q: J'ai K à mon K1, et pas d'autres pièces. Vous n'avez que K en K6 et R en R1. C'est votre déménagement. À quoi joues-tu?

A: (Après une pause de 15 secondes) R-R8 mat.

La méthode des questions et réponses semble convenir pour introduire presque tous les domaines de l'activité humaine que nous souhaitons inclure.

Nous ne souhaitons pas pénaliser la machine pour son incapacité à briller dans les concours de beauté, ni pénaliser un homme pour avoir perdu dans une course contre un avion. Les conditions de notre jeu rendent ces handicaps non pertinents. Les « témoins » peuvent se vanter, s'ils le jugent bon, autant qu'ils veulent de leurs charmes, de leur force ou de leur héroïsme, mais l'interrogateur ne peut exiger des démonstrations pratiques.

Le jeu peut-être être critiqué au motif que les cotes pèsent trop lourdement contre la machine. Si l'homme essayait de faire semblant d'être la machine, il ferait clairement une très mauvaise performance. Il serait tout de suite trahi par la lenteur et l'imprécision de l'arithmétique.

Les machines ne peuvent-elles pas réaliser quelque chose qui devrait être décrit comme pensant mais qui est très différent de ce que fait un homme ? Cette objection est très forte, mais au moins pouvons-nous dire que si, néanmoins, une machine peut être construite pour jouer le jeu de l'imitation de manière satisfaisante, nous n'avons pas besoin d'être troublés par cette objection.

On pourrait dire qu'en jouant au "jeu de l'imitation", la meilleure stratégie pour la machine peut éventuellement être autre chose que l'imitation du comportement d'un homme. C'est possible, mais je pense qu'il est peu probable qu'il y ait un grand effet de ce genre. En tout cas, il n'est nullement question d'étudier ici la théorie du jeu, et on supposera que la meilleure stratégie est d'essayer d'apporter des réponses qui seraient naturellement données par un homme.

# 3. Les Machines concernées dans le Jeu.

La question que nous posons au § 1 ne sera pas tout à fait définie tant que nous n'aurons pas précisé ce que nous entendons par le mot « machine ». Il est naturel que nous souhaitions permettre à toutes sortes de techniques d'ingénierie d'être utilisées dans nos machines. Nous souhaitons également permettre à un ingénieur ou à une équipe d'ingénieurs de construire une machine qui fonctionne, mais dont le mode de fonctionnement ne peut être décrit de manière satisfaisante par ses constructeurs parce qu'ils ont appliqué une méthode largement expérimentale. Enfin, nous voulons exclure des machines les hommes nés de manière habituelle. C'est difficile

encadrer les définitions de manière à satisfaire ces trois conditions. On pourrait

insister par exemple pour que l'équipe d'ingénieurs soit du même sexe, mais cela ne serait pas vraiment satisfaisant, car il est probablement possible d'élever un individu complet à partir d'une seule cellule de la peau (disons) d'un homme. Le faire serait un exploit de technique biologique méritant les plus grands éloges, mais nous ne serions pas enclins à le considérer comme un cas de « construction d'une machine pensante ». Cela nous incite à abandonner l'exigence selon laquelle toutes les techniques doivent être autorisées. Nous sommes d'autant plus disposés à le faire que l'intérêt actuel pour les « machines pensantes » a été suscité par un type particulier de machine, généralement appelé « ordinateur électronique » ou « ordinateur numérique ». Suite à cette suggestion, nous n'autorisons que les ordinateurs numériques à participer à notre jeu.

Cette restriction apparaît à première vue comme très drastique. J'essaierai de montrer qu'il n'en est pas ainsi dans la réalité. Pour ce faire, il est nécessaire de présenter brièvement la nature et les propriétés de ces ordinateurs.

On peut dire aussi que cette identification des machines aux calculateurs numériques, comme notre critère de "penser", ne sera insatisfaisante que si (contrairement à ce que je pense), il s'avère que les calculateurs numériques sont incapables de faire bonne figure dans le jeu.

Il existe déjà un certain nombre d'ordinateurs numériques en état de marche, et on peut se demander : « Pourquoi ne pas tenter l'expérience tout de suite ? Il serait facile de satisfaire aux conditions du jeu. Un certain nombre d'interrogateurs pourraient être utilisés et des statistiques compilées pour montrer à quelle fréquence la bonne identification a été donnée. La réponse courte est que nous ne demandons pas si tous les ordinateurs numériques fonctionneraient bien dans le jeu ni si les ordinateurs actuellement disponibles fonctionneraient bien, mais s'il existe des ordinateurs imaginables qui fonctionneraient bien. Mais ce n'est que la réponse courte. Nous verrons cette question sous un jour différent plus tard.

# 4. Ordinateurs numériques.

L'idée derrière les ordinateurs numériques peut être expliquée en disant que ces machines sont destinées à effectuer toutes les opérations qui pourraient être effectuées par un ordinateur humain. L'ordinateur humain est censé suivre des règles fixes ; il n'a pas le pouvoir de s'en écarter dans le moindre détail. On peut supposer que ces règles sont fournies dans un livre, qui est modifié chaque fois qu'il est affecté à un nouveau travail. Il a aussi une quantité illimitée de papier sur lequel il fait ses calculs. Il peut aussi faire ses multiplications et ses additions sur une « machine de bureau », mais ce n'est pas important.

Si nous utilisons l'explication ci-dessus comme définition, nous courrons le risque d'une circularité de l'argumentation. Nous foites cela en donnant un aperçu des moyens

par lequel l'effet désiré est atteint. Un ordinateur numérique peut généralement être considéré comme composé de trois partiesÿ:

- (i) Magasin.
- (ii) Unité exécutive.
- (iii) Contrôle.

Le magasin est un magasin d'informations, et correspond au papier de l'ordinateur humain, que ce soit le papier sur lequel il fait ses calculs ou celui sur lequel est imprimé son livre de règles. Dans la mesure où l'ordinateur humain fait des calculs dans sa tête, une partie du magasin correspondra à sa mémoire.

L'unité exécutive est la partie qui effectue les différentes opérations élémentaires intervenant dans un calcul. La nature de ces opérations individuelles varie d'une machine à l'autre. Habituellement, des opérations assez longues peuvent être effectuées telles que "Multiplier 3540675445 par 7076345687", mais dans certaines machines, seules des opérations très simples telles que "Ecrire 0" sont possibles.

Nous avons mentionné que le "livre de règles" fourni à l'ordinateur est remplacé dans la machine par une partie du magasin. On l'appelle alors la « table d'instructions ». Il est du devoir du contrôle de veiller à ce que ces instructions soient respectées correctement et dans le bon ordre. Le contrôle est construit de manière à ce que cela se produise nécessairement.

Les informations dans le magasin sont généralement divisées en paquets de taille moyennement petite. Dans une machine, par exemple, un paquet peut être composé de dix chiffres décimaux. Des numéros sont attribués aux parties du magasin dans lesquelles les divers paquets d'informations sont stockés, d'une manière systématique. Une instruction typique pourrait dire—

'Ajouter le nombre stocké en position 6809 à celui en 4302 et remettre le résultat dans cette dernière position de stockage'.

Inutile de dire que cela ne se produirait pas dans la machine exprimée en anglais. Il serait plus probablement codé sous une forme telle que 6809430217. Ici, 17 indique laquelle des diverses opérations possibles doit être effectuée sur les deux nombres. Dans ce cas, l'opération est celle décrite ci-dessus, à savoir. 'Ajoutez le numéro. . . . .' On remarquera que l'instruction occupe 10 chiffres et forme ainsi un paquet d'informations, très commodément. La commande prendra normalement les instructions à suivre dans l'ordre des positions dans lesquelles elles sont stockées, mais occasionnellement une instruction telle que

'Maintenant, obéissez à l'instruction stockée en position 5606, et continuez à partir de on peut rencontrer, ou encore

'Si la position 4505 contient 0 obéir ensuite à l'instruction stockée en 6707, sinon continuer tout droit.'

Les instructions de ces derniers types sont très importantes car elles permettent de répéter une séquence d'opérations encore et encore jusqu'à ce qu'une condition soit remplie, mais ce faisant, d'obéir, non pas à de nouvelles instructions à chaque répétition, mais aux mêmes à chaque fois. et encore. Pour prendre une analogie domestique. Supposons que Mère veuille que Tommy passe chez le cordonnier tous les matins en se rendant à l'école pour voir si ses chaussures sont prêtes, elle peut lui redemander chaque matin. Sinon, elle peut coller une fois pour toutes un avis dans le hall qu'il verra quand il partira pour

l'école et qui lui dit d'appeler les chaussures, et aussi de détruire l'avis à son retour s'il a les chaussures avec lui.

Le lecteur doit accepter comme un fait que les ordinateurs numériques peuvent être construits, et ont en effet été construits, selon les principes que nous avons décrits, et qu'ils peuvent en fait imiter de très près les actions d'un ordinateur humain.

Le livre de règles que nous avons décrit comme utilisant notre ordinateur humain est bien sûr une fiction commode. Les vrais ordinateurs humains se souviennent vraiment de ce qu'ils ont à faire. Si l'on veut faire en sorte qu'une machine imite le comportement de l'ordinateur humain dans une opération complexe, il faut lui demander comment cela se fait, puis traduire la réponse sous la forme d'un tableau d'instructions. La construction de tables d'instructions est généralement décrite comme de la «ÿprogrammationÿ». Pour 'programmer une machine pour effectuer l'opération A'

signifie mettre la table d'instructions appropriée dans la machine afin qu'elle fasse A.

Une variante intéressante de l'idée d'un ordinateur numérique est un «ordinateur numérique avec un élément aléatoire». Ceux-ci ont des instructions impliquant le lancement d'un dé ou un processus électronique équivalent; une de ces instructions pourrait être, par exemple, "Lancez le dé et mettez le nombre résultant dans la mémoire 1000". Parfois, une telle machine est décrite comme ayant le libre arbitre (bien que je n'utiliserais pas cette expression moi-même). Il n'est normalement pas possible de déterminer à partir de l'observation d'une machine si elle a un élément aléatoire, car un effet similaire peut être produit par des dispositifs tels que faire dépendre les choix des chiffres de la décimale pour  $\ddot{y}$ .

La plupart des ordinateurs numériques actuels n'ont qu'un magasin fini. Il n'y a aucune difficulté théorique dans l'idée d'un ordinateur avec un magasin illimité. De

Bien sûr, seule une partie finie peut avoir été utilisée à un moment donné. De même, seule une quantité finie peut avoir été construite, mais nous pouvons imaginer de plus en plus être ajoutés au fur et à mesure des besoins. De tels ordinateurs ont un intérêt théorique particulier et seront appelés ordinateurs à capacité infinitive.

L'idée d'un ordinateur numérique est ancienne. Charles Babbage , professeur lucasien de mathématiques à Cambridge de 1828 à 1839, a conçu une telle machine, appelée Analytical Engine, mais elle n'a jamais été achevée. Bien que Babbage ait eu toutes les idées essentielles, sa machine n'était pas à l'époque une perspective très attrayante. La vitesse qui aurait été disponible serait certainement plus rapide qu'un ordinateur humain mais quelque chose comme 100 fois plus lente que la machine de Manchester, elle-même l'une des plus lentes des machines modernes. Le stockage devait être purement mécanique, à l'aide de roues et de cartes.

Le fait que la machine analytique de Babbage devait être entièrement mécanique nous aidera à nous débarrasser d'une superstition. On attache souvent de l'importance au fait que les ordinateurs numériques modernes sont électriques et que le système nerveux est également électrique. Puisque la machine de Babbage n'était pas électrique, et puisque tous les ordinateurs numériques sont en un sens équivalents, on voit que cette utilisation de l'électricité ne peut pas avoir d'importance théorique. Bien sûr, l'électricité intervient généralement en ce qui concerne la signalisation rapide, il n'est donc pas surprenant que nous la trouvions dans ces deux connexions. Dans le système nerveux, les phénomènes chimiques sont au moins aussi importants que les phénomènes électriques. Dans certains ordinateurs, le système de stockage est principalement acoustique. La caractéristique d'utiliser l'électricité n'est donc perçue que comme une similitude très superficielle. Si nous voulons trouver de telles similitudes, nous devrions plutôt chercher d analogies de fonction.

# 5. Universalité des ordinateurs numériques.

Les calculateurs numériques considérés dans la dernière section peuvent être classés parmi les « machines à états discrets ». Ce sont des machines qui se déplacent par sauts ou claquements brusques d'un état bien défini à un autre. Ces états sont suffisamment différents pour ignorer la possibilité d'une confusion entre eux. À proprement parler, il n'y a pas de telles machines.

Tout bouge vraiment en continu. Mais il existe de nombreux types de machines qui peuvent être *considérées* avec profit comme des machines à états discrets. Par exemple, en considérant les interrupteurs d'un système d'éclairage, c'est une fiction commode que chaque interrupteur doit être définitivement allumé ou définitivement éteint. Il doit y avoir des positions intermédiaires, mais dans la plupart des cas, nous pouvons les oublier.

Comme exemple d'une machine à états nous pourrions

considérez une roue qui clique sur 120° une fois par seconde, mais peut être arrêtée par un levier qui peut être actionné de l'extérieurÿ; de plus une lampe doit s'allumer dans une des positions de la roue. Cette machine pourrait être décrite abstraitement comme suit. L'état interne de la machine (qui est décrit par la position de la roue) peut être q1, q2 ou q3. Il y a un signal d'entrée i0 ou i1, (position du levier). L'état interne à tout moment est déterminé par le dernier état et le signal d'entrée selon le tableau

|              |    |    | Dernier état |    |  |
|--------------|----|----|--------------|----|--|
|              |    | q1 | q2           | q3 |  |
| Contribution | iO | q2 | q3           | q1 |  |
|              | i1 | q1 | q2           | q3 |  |

Les signaux de sortie, la seule indication visible de l'extérieur de l'état interne (la lumière) sont décrits par le tableau

| État   | q1 | q2 | q3 |
|--------|----|----|----|
| Sortir | 00 | 00 | 01 |

Cet exemple est typique des machines à états discrets. Ils peuvent être décrits par de tels tableaux à condition qu'ils n'aient qu'un nombre fini d'états possibles.

Il semblera que compte tenu de l'état initial de la machine et des signaux d'entrée, il est toujours possible de prédire tous les états futurs. Cela rappelle la vision de Laplace selon laquelle à partir de l'état complet de l'univers à un moment donné, tel que décrit par les positions et les vitesses de toutes les particules, il devrait être possible de prédire tous les états futurs. La prédiction que nous envisageons est cependant plus proche de la praticabilité que celle envisagée par Laplace. Le système de « l'univers dans son ensemble » est tel que de très petites erreurs dans les conditions initiales peuvent avoir un effet écrasant ultérieurement. Le déplacement d'un seul électron d'un milliardième de centimètre à un moment donné pourrait faire la différence entre un homme tué par une avalanche un an plus tard ou s'enfuyant. C'est une propriété essentielle des systèmes mécaniques que nous avons appelés "machines à états discrets"

que ce phénomène ne se produit pas. Même lorsque nous considérons les machines physiques réelles au lieu des machines idéalisées, une connaissance raisonnablement précise de l'état à un moment donne une connaissance raisonnablement précise un certain nombre d'étapes plus tard.

Comme nous l'avons mentionné, les ordinateurs numériques appartiennent à la classe des machines à états discrets. Mais le nombre d'états dont une telle machine est capable est généralement extrêmement grand. Par exemple, le nombre de la machine qui travaille actuellement à Manchester est d'environ 2 165 000, c'est-à *-dire* environ 1 050 000 Comparez cela avec notre exemple de la molette cliquable décrite ci-dessus, qui avait trois états. Il n'est pas difficile de voir pourquoi le nombre d'états devrait être si immense. L'ordinateur comprend un magasin correspondant au papier utilisé par un ordinateur humain. Il doit être possible d'écrire dans le magasin n'importe laquelle des combinaisons de symboles qui auraient pu être écrites sur le papier. Pour simplifier, supposons que seuls les chiffres de 0 à 9 soient utilisés comme symboles. Les variations d'écriture sont ignorées. Supposons que l'ordinateur dispose de 100 feuilles de papier contenant chacune 50 lignes avec de la place pour 30 chiffres. Alors le nombre d'états est 10100x50x30

c'est-à -dire 10150 000 . C'est à propos de

le nombre d'états de trois machines de Manchester réunies. Le logarithme à base deux du nombre d'états est généralement appelé la « capacité de stockage » de la machine. Ainsi la machine de Manchester a une capacité de stockage d'environ 165 000 et la machine à roues de notre exemple d'environ 1,6. Si deux machines sont assemblées, leurs capacités doivent être additionnées pour obtenir la capacité de la machine résultante. Cela conduit à la possibilité d'énoncés tels que "La machine de Manchester contient 64 pistes magnétiques chacune d'une capacité de 2560, huit tubes électroniques d'une capacité de 1280. Le stockage divers s'élève à environ 300, soit un total de 174 380".

Étant donné le tableau correspondant à une machine à états discrets, il est possible de prédire ce qu'elle fera. Il n'y a aucune raison pour que ce calcul ne soit pas effectué au moyen d'un calculateur numérique. Pourvu qu'il puisse être exécuté suffisamment rapidement, l'ordinateur numérique pourrait imiter le comportement de n'importe quelle machine à états discrets. Le jeu d'imitation pourrait alors être joué avec la machine en question (comme B) et l'ordinateur numérique imitant (comme A) et l'interrogateur serait incapable de les distinguer.

Bien sûr, l'ordinateur numérique doit avoir une capacité de stockage adéquate ainsi qu'un fonctionnement suffisamment rapide. De plus, il doit être reprogrammé pour chaque nouvelle machine que l'on veut imiter.

Cette propriété spéciale des ordinateurs numériques, qu'ils peuvent imiter n'importe quelle machine à états discrets, est décrite en disant qu'ils sont *universels*Machines. L'existence de machines dotées de cette propriété a pour conséquence importante que, compte tenu de la vitesse mise à part, il n'est pas nécessaire de concevoir diverses nouvelles machines pour effectuer divers processus de calcul. Ils peuvent tous être

fait avec un ordinateur numérique, convenablement programmé pour chaque cas. On verra qu'en conséquence, tous les ordinateurs numériques sont en un sens équivalent.

Nous pouvons maintenant reprendre le point soulevé à la fin du §3. Il a été suggéré provisoirement que la question « Les machines peuvent-elles penser ? devrait être remplacé par 'Y a-t-il des ordinateurs numériques imaginables qui feraient bien dans le jeu de l'imitation ?' Si nous le souhaitons, nous pouvons rendre ceci superficiellement plus général et demander «ÿY a-t-il des machines à états discrets qui feraient bienÿ Mais compte tenu de la propriété d'universalité, nous voyons que l'une ou l'autre de ces questions est équivalente à celle-ci : « Fixons notre attention sur un ordinateur numérique particulier *C*. Est-il vrai qu'en modifiant cet ordinateur pour qu'il ait une mémoire adéquate, en augmentant convenablement sa vitesse ? d'action, et en lui donnant un programme approprié, *C* peut être amené à jouer de manière satisfaisante le rôle de A dans le jeu de l'imitation. le rôle de B étant pris par un homme ?

# 6. Opinions contraires sur la guestion principale.

Nous pouvons maintenant considérer que le terrain est déblayé et nous sommes prêts à passer au débat sur notre question : « Les machines peuvent-elles penser ? et sa variante citée à la fin de la dernière section. Nous ne pouvons pas abandonner complètement la forme originale du problème, car les opinions divergeront quant à l'opportunité de la substitution et nous devons au moins écouter ce qui doit être dit à ce sujet.

Cela simplifiera les choses pour le lecteur si j'explique d'abord mes propres croyances en la matière. Considérons d'abord la forme la plus précise de la question. Je pense que dans une cinquantaine d'années, il sera possible de programmer des ordinateurs, avec une capacité de stockage d'environ 109, de leur faire jouer si bien le jeu de l'imitation qu'un interrogateur moyen n'aura pas plus de 70 % de chances de faire la bonne identification après cinq minutes d'interrogatoire. La question initiale, "Les machines peuvent-elles penser!" Je pense que c'est trop vide de sens pour mériter une discussion. Néanmoins je crois qu'à la fin du siècle l'usage des mots et l'opinion générale cultivée auront tellement changé qu'on pourra parler de machines pensantes sans s'attendre à être contredit. Je crois en outre qu'il n'y a aucun but utile à dissimuler ces croyances. L'opinion populaire selon laquelle les scientifiques procèdent inexorablement d'un fait bien établi à un fait bien établi, sans jamais être influencés par une conjecture non prouvée, est tout à fait erronée. Pourvu qu'il soit clairement établi quels sont les faits prouvés et lesquels sont des conjectures, aucun dommage ne peut en résulter. Les conjectures sont d'une grande importance car elles suggèrent des pistes de recherche utiles.

442

Je passe maintenant à l'examen des opinions opposées aux miennes.

(1) L'objection théologique. La pensée est une fonction de l'âme immortelle de l'homme. Dieu a donné une âme immortelle à chaque homme et femme, mais pas à tout autre animal ou aux machines. Par conséquent, aucun animal ou machine ne peut penser.

Je ne peux en accepter aucune partie, mais je tenteraj de répondre en termes théologiques. Je trouverais l'argument plus convaincant si les animaux étaient classés avec les hommes, car il y a une plus grande différence, à mon avis, entre l'animé typique et l'inanimé qu'il n'y en a entre l'homme et les autres animaux. Le caractère arbitraire du point de vue orthodoxe devient plus clair si nous considérons comment il pourrait apparaître à un membre d'une autre communauté religieuse. Comment les chrétiens considèrent-ils la vision musulmane selon laquelle les femmes n'ont pas d'âme ? Mais laissons ce point de côté et revenons à l'argument principal. Il me semble que l'argument cité ci-dessus implique une restriction sérieuse de la toute-puissance du Tout-Puissant. Il est admis qu'il y a certaines choses qu'il ne peut pas faire comme faire un égal à deux, mais ne devrions-nous pas croire qu'il a la liberté de conférer une âme à un éléphant s'il le juge bon ? Nous pourrions nous attendre à ce qu'il n'exerce ce pouvoir qu'en conjonction avec une mutation qui a fourni à l'éléphant un cerveau convenablement amélioré pour répondre aux besoins de cette âme. Un argument de forme exactement similaire peut être avancé pour le cas des machines. Cela peut sembler différent car il est plus difficile à « avaler ». Mais cela signifie vraiment seulement que nous pensons qu'il serait moins probable qu'il considère les circonstances appropriées pour conférer une âme. Les circonstances en question sont discutées dans le reste de cet article. En essayant de construire de telles machines, nous ne devrions pas usurper irrévérencieusement Son pouvoir de créer des âmes, pas plus que nous ne le sommes dans la procréation d'enfants : nous sommes plutôt, dans les deux cas, des instruments de Sa volonté fournissant des demeures aux âmes qu'Il crée.

Cependant, ce n'est qu'une spéculation. Je ne suis pas très impressionné par les arguments théologiques, quels qu'ils soient. De tels arguments ont souvent été jugés insatisfaisants dans le passé. À l'époque de Galilée, on soutenait que les textes « Et le soleil s'arrêta. . . et ne s'empressa pas de descendre environ un jour entier » (Josué x. 13) et « Il posa le

Peut-être que ce point de vue est hérétique. Saint Thomas d'Aquin (Summa Theologica, cité par Bertrand Russell, p. 480) déclare que Dieu ne peut pas faire qu'un homme n'ait pas d'âme. Mais cela peut ne pas être une véritable restriction à Ses pouvoirs, mais seulement le résultat du fait que les âmes des hommes sont immortelles, et donc indestructibles.

fondements de la terre, afin qu'elle ne bouge à aucun moment » (Psaume cv. 5) étaient une réfutation adéquate de la théorie copernicienne. Dans l'état actuel de nos connaissances, un tel argument semble futile. Lorsque cette connaissance n'était pas disponible, cela faisait une impression tout à fait différente.

(2) L'objection «ÿla tête dans le sableÿ». « Les conséquences de la pensée des machines seraient trop terribles. Espérons et croyons qu'ils ne peuvent pas le faire.

Cet argument est rarement exprimé aussi ouvertement que dans le formulaire cidessus. Mais cela affecte la plupart d'entre nous qui y pensons. Nous aimons croire
que l'homme est d'une manière subtile supérieur au reste de la création. Il est
préférable qu'il puisse être démontré qu'il est *nécessairement* supérieur, car alors il n'y
a aucun danger qu'il perde sa position de commandement. La popularité de l'argument
théologique est clairement liée à ce sentiment. Il est susceptible d'être assez fort chez
les intellectuels, car ils apprécient plus que les autres le pouvoir de penser et sont plus
enclins à fonder leur croyance en la supériorité de l'homme sur ce pouvoir.

Je ne pense pas que cet argument soit suffisamment substantiel pour nécessiter une réfutation. La consolation serait plus appropriée : peut-être faudrait-il la chercher dans la transmigration des âmes.

(3) L'objection mathématique. Il existe un certain nombre de résultats de logique mathématique qui peuvent être utilisés pour montrer qu'il existe des limites aux pouvoirs des machines à états discrets. Le plus connu de ces résultats est connu sous le nom de théorème de Gödel1 et montre que dans tout système logique suffisamment puissant, des énoncés peuvent être formulés qui ne peuvent être ni prouvés ni réfutés dans le système, à moins que le système lui-même ne soit incohérent. Il existe d'autres résultats, à certains égards similaires, dus à Church, Kleene, Rosser et Turing. Ce dernier résultat est le plus commode à considérer, puisqu'il se réfère directement aux machines, alors que les autres ne peuvent être utilisés que dans un argument relativement indirect : par exemple, si le théorème de Gödel doit être utilisé, nous devons en plus avoir des moyens

de décrire les systèmes logiques en termes de machines, et les machines en termes de systèmes logiques. Le résultat en question fait référence à un type de machine qui est essentiellement un ordinateur numérique à capacité infinie. Il indique qu'il y a certaines choses qu'une telle machine ne peut pas faire. S'il est configuré pour donner des réponses à des questions comme dans le jeu de l'imitation, il y aura des questions auxquelles il donnera soit une mauvaise réponse, soit il ne donnera pas de réponse du tout, quel que soit le temps imparti pour une réponse. Il peut bien sûr y avoir beaucoup

Les noms d'auteurs en italique renve

de telles questions, et les questions auxquelles une machine ne peut pas répondre peuvent être répondues de manière satisfaisante par une autre. Nous supposons bien sûr pour le moment que les questions sont du type auxquelles une réponse « Oui » ou « Non » est appropriée, plutôt que des questions telles que « Que pensez-vous de Picasso ?

Les questions sur lesquelles nous savons que les machines doivent échouer sont du type : « Considérez la machine spécifiée comme suit. . . . Cette machine répondra-t-elle un jour 'Oui' à n'importe quelle question ? Les points doivent être remplacés par une description d'une machine sous une forme standard, ce qui pourrait être quelque chose comme celle utilisée au § 5. Lorsque la machine décrite entretient une certaine relation relativement simple avec la machine qui est interrogée, on peut montrer que la réponse est soit fausse, soit absente. C'est le résultat mathématique : on prétend qu'il prouve un handicap des machines auquel l'intellect humain n'est pas soumis.

La réponse courte à cet argument est que bien qu'il soit établi qu'il existe des limitations aux pouvoirs d'une machine particulière, il a seulement été déclaré, sans aucune sorte de preuve, qu'aucune de ces limitations ne s'applique à l'intellect humain. Mais je ne pense pas que ce point de vue puisse être rejeté aussi légèrement. Chaque fois qu'on pose à l'une de ces machines la question critique appropriée et qu'elle donne une réponse définitive, nous savons que cette réponse doit être fausse, et cela nous donne un certain sentiment de supériorité. Ce sentiment est-il illusoire ? C'est sans doute tout à fait authentique, mais je ne pense pas qu'il faille y attacher trop d'importance. Nous donnons trop souvent nous-mêmes de mauvaises réponses aux questions pour être justifiés de nous réjouir d'une telle preuve de faillibilité de la part des machines. De plus, notre supériorité ne peut se faire sentir en pareille occasion que par rapport à la seule machine sur laquelle nous

ont marqué notre petit triomphe. Il ne serait pas question de triompher simultanément de toutes les machines. Bref, il pourrait y avoir des hommes plus intelligents que n'importe quelle machine donnée, mais là encore il pourrait y avoir d'autres machines encore plus intelligentes, et ainsi de suite.

Ceux qui s'en tiennent à l'argument mathématique seraient, je pense, pour la plupart disposés à accepter le jeu de l'imitation comme base de discussion. Ceux qui croient aux deux objections précédentes ne seraient probablement intéressés par aucun critère.

(4) L'argument de la conscience. Cet argument est très bien exprimé dans le Lister Oration du professeur Jefferson pour 1949, que je cite. "Ce n'est que lorsqu'une machine peut écrire un sonnet ou composer un concerto à cause des pensées et des émotions ressenties, et non par la chute fortuite des symboles, que nous pourrions convenir que la machine égale le cerveau - c'est-à-dire non seulement écrire

mais sachez qu'il l'avait écrit. Aucun mécanisme ne pourrait ressentir (et pas seulement signal artificiel, un stratagème facile) le plaisir de ses succès, le chagrin quand ses vannes fusionnent, être réchauffé par la flatterie, être rendu malheureux par ses erreurs, être charmé par le sexe, être en colère ou déprimé quand il ne peut pas obtenir ce qu'il veut.

Cet argument semble être un déni de la validité de notre test.

Selon la forme la plus extrême de cette conception, le seul moyen d'être sûr qu'une machine pense est d' *être* la machine et de ressentir

penser soi-même. On pourrait alors décrire ces sentiments au monde, mais bien sûr personne ne serait justifié de s'en apercevoir. De même, selon ce point de vue, la seule façon de savoir ce qu'un *homme* pense est d'être cet homme en particulier. C'est en fait le point de vue solipsiste. C'est peut-être le point de vue le plus logique à avoir, mais cela rend la communication des idées difficile. A est susceptible de croire «ÿA pense mais B ne pense pasÿ» tandis que B croit «ÿB pense mais

A ne le fait pas. Au lieu de discuter continuellement sur ce point, il est d'usage d'avoir la convention polie que tout le monde pense.

Je suis sûr que le professeur Jefferson ne souhaite pas adopter le point de vue extrême et solipsiste. Il serait probablement tout à fait disposé à accepter le jeu de l'imitation comme test. Le jeu (le joueur B étant omis) est fréquemment utilisé dans la pratique sous le nom de *viva voce* pour découvrir si quelqu'un comprend vraiment quelque chose ou l'a "appris à la manière d'un perroquet". Écoutons une partie d'une telle *viva voceÿ*:

Interrogateur : Dans la première ligne de votre sonnet qui se lit 'Dois-je te comparer à un jour d'été', 'un jour de printemps' ne ferait-il pas aussi bien ou mieux ?

Témoin : Il ne scannerait pas.

Interrogateurÿ: Que diriez-vous d'un "ÿjour d'hiverÿ?" Cela scannerait bien.

Témoin : Oui, mais personne ne veut être comparé à un jour d'hiver.

Interrogateurÿ: Diriez-vous que M. Pickwick vous a rappelé Noëlÿ?

Témoin : D'une certaine manière.

Interrogateurÿ: Pourtant, Noël est un jour d'hiver, et je ne pense pas que M. Pickwick se soucierait de la comparaison.

Témoin : Je ne pense pas que vous soyez sérieux. Par écorchure d'hiver, on entend une journée d'hiver typique, plutôt qu'une journée spéciale comme Noël.

Etc. Que dirait le professeur Jefferson si la machine à écrire des sonnets était capable de répondre ainsi de *vive voix* ? je ne sais pas

s'il considérerait la machine comme "un simple signal artificiel" ces réponses, mais si les réponses étallement satisfaisantes et soutenues qu'en

le passage ci-dessus, je ne pense pas qu'il le décrirait comme "un artifice facile". Cette phrase est, je pense, destinée à couvrir des dispositifs tels que l'inclusion dans la machine d'un enregistrement de quelqu'un lisant un sonnet, avec une commutation appropriée pour l'allumer de temps en temps.

Bref, je pense que la plupart de ceux qui soutiennent l'argument de la conscience pourraient être persuadés de l'abandonner plutôt que d'être contraints à la position solipsiste. Ils seront alors probablement disposés à accepter notre test.

Je ne veux pas donner l'impression que je pense qu'il n'y a pas de mystère au sujet de la conscience. Il y a, par exemple, quelque chose d'un paradoxe lié à toute tentative de le localiser. Mais je ne pense pas que ces mystères aient nécessairement besoin d'être résolus avant que nous puissions répondre à la question qui nous préoccupe dans cet article.

(5) Arguments de divers handicaps. Ces arguments prennent la forme : « Je vous accorde que vous pouvez faire faire à des machines toutes les choses que vous avez mentionnées mais vous ne pourrez jamais en faire faire une seule pour faire X ». De nombreuses caractéristiques X sont suggérées à cet égard. Je vous propose une sélection :

Être gentil, débrouillard, beau, amical (p. 448), avoir de l'initiative, avoir le sens de l'humour, distinguer le vrai du faux, faire des erreurs (p. 448), tomber amoureux, déguster des fraises et de la crème (p. 448), en faire tomber amoureux, apprendre de l'expérience (pp. 456 sq.), bien utiliser les mots, être le sujet de sa propre pensée (p. 449), avoir autant de diversité de comportement qu'un homme, faire quelque chose de vraiment nouveau (p. 450). (Certains de ces handicaps font l'objet d'une attention particulière, comme l'indiquent les numéros de page.)

Aucun support n'est généralement proposé pour ces déclarations. Je crois qu'ils sont pour la plupart fondés sur le principe de l'induction scientifique. Un homme a vu des milliers de machines dans sa vie. De ce qu'il en voit, il tire

un certain nombre de conclusions générales. Ils sont laids, chacun est conçu pour un but très limité, lorsqu'il est requis pour un but très différent, ils sont inutiles, la variété de comportement de chacun d'eux est très petite, etc., etc.

Naturellement, il conclut que ce sont des propriétés nécessaires des machines en général. Bon nombre de ces limitations sont associées à la très petite capacité de stockage de la plupart des machines. (Je suppose que l'idée de capacité de stockage est étendue d'une manière ou d'une autre pour couvrir des machines autres que des machines à états discrets. La définition exacte n'a pas d'importance car aucune mathématique

l'exactitude est revendiquée dans la présente discussion.) Il y a quelques années, alors qu'on avait très peu entendu parler d'ordinateurs numériques, il était possible de susciter beaucoup d'incrédulité à leur sujet, si l'on mentionnait leurs propriétés sans décrire leur construction. Cela était vraisemblablement dû à une application similaire du principe d'induction scientifique. Ces applications du principe sont bien sûr largement inconscientes. Quand un enfant brûlé craint le feu et montre qu'il le craint en l'évitant, je dirais qu'il appliquait l'induction scientifique. (Je pourrais bien sûr aussi décrire son comportement de bien d'autres manières.) Les œuvres et les coutumes de l'humanité ne semblent pas être un matériau très approprié pour appliquer l'induction scientifique. Une très grande partie de l'espace-temps doit être investiguée, si l'on veut obtenir des résultats fiables. Sinon, nous pouvons (comme le font la plupart des enfants anglais) décider que tout le monde parle anglais et qu'il est idiot d'apprendre le français.

Il y a, cependant, des remarques particulières à faire au sujet de bon nombre des handicaps qui ont été mentionnés. L'incapacité d'apprécier les fraises et la crème peut avoir semblé frivole au lecteur. Peut-être qu'une machine pourrait être fabriquée pour profiter de ce plat délicieux, mais toute tentative de le faire serait idiote. Ce qui est important à propos de ce handicap, c'est qu'il contribue à certains des autres handicaps, *par exemple* à la difficulté du même type de convivialité entre l'homme et la machine qu'entre l'homme blanc et l'homme blanc, ou entre l'homme noir et l'homme noir.

L'affirmation selon laquelle "les machines ne peuvent pas faire d'erreurs" semble curieuse. On est tenté de répliquer : « En sont-ils plus mal pour ça ? Mais adoptons une attitude plus sympathique et essayons de voir ce que cela signifie vraiment. Je pense que cette critique peut être expliquée en termes de jeu d'imitation. On prétend que l'interrogateur pouvait distinguer la machine de l'homme simplement en leur posant un certain nombre de problèmes d'arithmétique. La machine serait démasquée en raison de sa précision mortelle. La réponse à cela est simple. La machine (programmée pour jouer au jeu) n'essaierait pas de donner les *bonnes* réponses aux problèmes arithmétiques. Cela introduirait délibérément des erreurs d'une manière calculée pour confondre l'interrogateur. Un défaut mécanique se manifesterait probablement par une décision inappropriée quant à la sorte d'erreur à commettre dans l'arithmétique. Même cette interprétation de la critique n'est pas suffisamment sympathique. Mais nous ne pouvons pas nous permettre d'aller beaucoup plus loin. Il me semble que cette critique relève d'une confusion entre deux sortes d'erreurs. On peut les appeler « erreurs de fonctionnement » et « erreurs de conclusion ». Les erreurs de fonctionnement sont dues à

un défaut mécanique ou électrique qui provoque le comportement de la machine autrement qu'il n'a été conçu pour le faire. Dans les discussions philosophiques, on aime ignorer la possibilité de telles erreurs ; on parle alors de « machines abstraites ». Ces machines abstraites sont des fictions mathématiques plutôt que

objets physiques. Par définition ils sont incapables d'erreurs de fonctionnement.

En ce sens, nous pouvons vraiment dire que "les machines ne peuvent jamais faire d'erreurs".

Des erreurs de conclusion ne peuvent survenir que lorsqu'une certaine signification est attachée aux signaux de sortie de la machine. La machine peut, par exemple, taper des équations mathématiques ou des phrases en anglais. Quand une fausse proposition est tapé on dit que la machine a commis une erreur de conclusion.

Il n'y a clairement aucune raison de dire qu'une machine ne peut pas faire ce genre d'erreur. Il peut ne rien faire d'autre que taper à plusieurs reprises '0 = 1'. Pour prendre un exemple moins pervers, il pourrait avoir une méthode pour tirer des conclusions par induction scientifique. Il faut s'attendre à ce qu'une telle méthode conduise parfois à des résultats erronés.

L'affirmation selon laquelle une machine ne peut pas être le sujet de sa propre pensée ne peut évidemment être résolue que s'il peut être démontré que la machine a *des* pensée avec *un* sujet. Néanmoins, « l'objet des opérations d'une machine » semble signifier quelque chose, du moins pour les personnes qui s'en occupent. Si, par exemple, la machine essayait de trouver une solution

de l'équation x  $^2$  ÿ 40x ÿ 11 = 0 on serait tenté de décrire cela l'équation comme faisant partie de l'objet de la machine à ce moment-là. Dans ce genre de sens, une machine peut sans aucun doute être son propre sujet. Elle peut être utilisée pour aider à l'élaboration de ses propres programmes ou pour prédire l'effet de modifications de sa propre structure. En observant les résultats de son propre comportement, il peut modifier ses propres programmes afin d'atteindre un objectif plus efficacement. Ce sont des possibilités du futur proche, plutôt que des rêves utopiques.

La critique selon laquelle une machine ne peut pas avoir beaucoup de diversité de comportement n'est qu'une manière de dire qu'elle ne peut pas avoir beaucoup de capacité de stockage. Jusqu'à assez récemment, une capacité de stockage ne serait-ce que d'un millier de chiffres était très rare.

Les critiques que nous examinons ici sont souvent des formes déguisées de l'argument de la conscience. Habituellement, si l'on soutient qu'une machine *peut* faire l'une de ces choses et décrit le type de méthode que la machine pourrait utiliser, on ne fera pas grande impression. On pense que la méthode (quelle qu'elle soit, car elle doit être mécanique) est

vraiment plutôt basique. Comparez la parenthèse dans la déclaration de Jefferson citée à la p. 21.

(6) Objection de Lady Lovelace. Nos informations les plus détaillées sur la machine analytique de Babbage proviennent d'un mémoire de Lady Lovelace. Elle y déclare : « La machine analytique n'a pas la prétention d'être à l' origine rien. Il peut faire tout ce que nous savons lui ordonner de faire » (ses italiques). Cette affirmation est citée par Hartree (p. 70) qui ajoute : « Cela n'implique pas qu'il ne soit pas possible de construire un équipement électronique qui « pensera par lui-même », ou dans lequel, en termes biologiques, on pourrait mettre en place un réflexe conditionné, qui servirait de base à « l'apprentissage ».

Que cela soit possible en principe ou non est une question stimulante et passionnante, suggérée par certains de ces développements récents. Mais il ne semblait pas que les machines construites ou projetées à l'époque possédaient cette propriété ».

Je suis entièrement d'accord avec Hartree sur ce point. On remarquera qu'il n'affirme pas que les machines en question n'avaient pas obtenu la propriété, mais plutôt que les preuves à la disposition de Lady Lovelace ne l'encourageaient pas à croire qu'elles l'avaient. Il est fort possible que les machines en question aient en quelque sorte obtenu cette propriété. Supposons qu'une machine à états discrets ait la propriété. Le moteur analytique était un ordinateur numérique universel, de sorte que, si sa capacité de stockage et sa vitesse étaient adéquates, il pouvait, par une programmation appropriée, être amené à imiter la machine en question. Cet argument n'est probablement pas venu à l'esprit de la comtesse ou de Babbage. En tout état de cause, ils n'étaient pas tenus de réclamer tout ce qui pouvait être réclamé.

Toute cette question sera reprise sous le titre de machines apprenantes.

Une variante de l'objection de Lady Lovelace affirme qu'une machine ne peut "jamais rien faire de vraiment nouveau". Cela peut être paré un instant avec la scie, 'Il n'y a rien de nouveau sous le soleil'. Qui peut être certain que le «ÿtravail originalÿ» qu'il a accompli n'était pas simplement la croissance de la graine plantée en lui par l'enseignement, ou l'effet de suivre des principes généraux bien connus.

Une meilleure variante de l'objection dit qu'une machine ne peut jamais "nous prendre par surprise". Cette déclaration est un défi plus direct et peut être relevée directement. Les machines me surprennent très fréquemment. C'est en grande partie parce que je ne fais pas suffisamment de calculs pour décider ce qu'ils doivent faire, ou plutôt parce que, bien que je fasse un calcul, je le fais de façon précipitée, négligente, en prenant des risques. Peut-être que je me dis : 'Je suppose que la tension ici

devrait être le même que là-basÿ: de toute façon, supposons que ce soit le cas.ÿ» Naturellement, je me trompe souvent, et le résultat est une surprise pour moi car au moment où l'expérience est faite, ces hypothèses ont été oubliées. Ces aveux m'exposent à des sermons au sujet de mes manières vicieuses, mais ne jetez aucun doute sur ma crédibilité lorsque je témoigne des surprises que j'éprouve.

Je ne m'attends pas à ce que cette réponse fasse taire mon critique. Il dira probablement que de telles surprises sont dues à un acte mental créatif de ma part, et ne font pas honneur à la machine. Cela nous ramène à l'argument de la conscience, et loin de l'idée de surprise. C'est une ligne d'argumentation que nous devons considérer comme fermée, mais il vaut peutêtre la peine de remarquer que l'appréciation de quelque chose d'aussi surprenant exige autant d'un «ÿacte mental créatify» que l'événement surprenant provienne d'un homme, d'un livre, d'une machine ou de quoi que ce soit. autre.

L'opinion selon laquelle les machines ne peuvent pas créer de surprises est due, je crois, à un sophisme auquel les philosophes et les mathématiciens sont particulièrement sujets. C'est l'hypothèse que dès qu'un fait est présenté à un esprit, toutes les conséquences de ce fait jaillissent dans l'esprit simultanément avec lui. C'est une hypothèse très utile dans de nombreuses circonstances, mais on oublie trop facilement qu'elle est fausse. Une conséquence naturelle de le faire est que l'on suppose alors qu'il n'y a aucune vertu dans le simple fait de tirer des conséquences à partir de données et de principes généraux.

(7) Argument de la continuité dans le système nerveux. Le système nerveux n'est certainement pas une machine à états discrets. Une petite erreur dans l'information sur la taille d'une impulsion nerveuse frappant un neurone peut faire une grande différence dans la taille de l'impulsion sortante. On peut soutenir que, cela étant, on ne peut pas s'attendre à pouvoir imiter le comportement du système nerveux avec un système à états discrets.

Il est vrai qu'une machine à états discrets doit être différente d'une machine continue. Mais si l'on s'en tient aux conditions de l'imitation

jeu, l'interrogateur ne pourra profiter de cette différence. La situation peut être rendue plus claire si nous considérons une autre machine continue plus simple. Un analyseur différentiel fera très bien l'affaire. (Un analyseur différentiel est un certain type de machine qui n'est pas du type à états discrets utilisé pour certains types de calcul.) Certains d'entre eux fournissent leurs réponses sous une forme typée et conviennent donc pour participer au jeu. Il ne serait pas possible pour un ordinateur numérique de prédire exactement quelles réponses l'analyseur différentiel donnerait à un problème, mais il serait tout à fait capable de donner le bon type de réponse. Par exemple, si on lui demande de

donner la valeur de  $\ddot{y}$  (en fait environ 3,1416) il serait raisonnable de choisir au hasard entre les valeurs 3,12, 3,13, 3,14, 3,15, 3,16 avec les probabilités de 0,05, 0,15, 0,55, 0,19, 0,06 (disons). Dans ces circonstances, il serait très difficile pour l'interrogateur de distinguer l'analyseur différentiel du calculateur numérique.

(8) L'argument de l'informalité du comportement. Il n'est pas possible de produire un ensemble de règles prétendant décrire ce qu'un homme devrait faire dans toutes les circonstances imaginables. On pourrait, par exemple, avoir pour règle de s'arrêter quand on voit un feu rouge et de repartir si on en voit un vert, mais que se passe-t-il si, par une faute quelconque, les deux apparaissent ensemble ? On peut peut-être décider qu'il est plus sûr de s'arrêter. Mais d'autres difficultés pourraient bien résulter de cette décision plus tard. Tenter de fournir des règles de conduite pour couvrir toutes les éventualités, même celles découlant des feux de circulation, semble impossible. Avec tout cela, je suis d'accord.

À partir de là, on soutient que nous ne pouvons pas être des machines. Je vais essayer de reproduire l'argument, mais je crains de ne pas lui rendre justice. Il semble fonctionner quelque chose comme ça. « Si chaque homme avait un ensemble défini de règles de conduite qui régissent sa vie, il ne serait pas mieux qu'une machine. Mais il n'y a pas de telles règles, donc les hommes ne peuvent pas être des machines. Le milieu non distribué est flagrant. Je ne pense pas que l'argument soit jamais présenté de cette façon, mais je crois que c'est néanmoins l'argument utilisé. Il peut cependant y avoir une certaine confusion entre « règles de conduite » et « lois de comportement » pour

brouiller le problème. Par « règles de conduite », j'entends des préceptes tels que « Arrêtezvous si vous voyez des feux rouges », sur lesquels on peut agir, et dont on peut être conscient. Par «ÿlois de comportementÿ», j'entends les lois de la nature appliquées au corps d'un homme, telles que «ÿsi vous le pincez, il couineraÿ». Si nous substituons des « lois de comportement qui règlent sa vie » aux « lois de conduite par lesquelles il règle sa vie » dans l'argument cité, le milieu non distribué n'est plus insurmontable. Car nous pensons qu'il est non seulement vrai qu'être régulé par des lois de comportement implique d'être une sorte de machine (mais pas nécessairement une machine à états discrets), mais qu'à l'inverse être une telle machine implique d'être régulé par de telles lois. Cependant, nous ne pouvons pas nous convaincre aussi facilement de l'absence de lois complètes de comportement que de règles complètes de conduite. Le seul moyen que nous connaissions pour trouver de telles lois est l'observation scientifique, et nous ne connaissons certainement aucune circonstance dans laquelle nous pourrions dire : "Nous avons suffisamment cherché". Il n'y a pas de telles lois.

Nous pouvons démontrer avec plus de force qu'une telle déclaration serait injustifiée.

Car supposons que nous puissions être sûrs de trouver de telles lois si elles existaient. Alors étant donné une machine à états discrets certainement être possible

découvrir par l'observation suffisamment à son sujet pour prédire son comportement futur, et cela dans un délai raisonnable, disons mille ans. Mais cela ne semble pas être le cas. J'ai mis en place sur l'ordinateur de Manchester un petit programme n'utilisant que 1000 unités de mémoire, dans lequel la machine munie d'un numéro à seize chiffres répond par un autre en deux secondes. Je défierais quiconque d'apprendre de ces réponses suffisamment sur le programme pour pouvoir prédire toute réponse à des valeurs non testées.

(9) L'argument de la perception extra-sensorielle. Je suppose que le lecteur est familier avec l'idée de perception extra-sensorielle et la signification des quatre éléments de celle-ci, à savoir. télépathie, clairvoyance, précognition et psychokinésie. Ces phénomènes inquiétants semblent nier toutes nos idées scientifiques habituelles. Comme nous voudrions les discréditer! Malheureusement, les preuves statistiques, du moins pour la télépathie, sont accablantes. Il est très difficile de réorganiser ses idées de manière à intégrer ces nouveaux faits. Une fois qu'on les a acceptés, croire aux fantômes et aux bogies ne semble pas être un grand pas. L'idée que nos corps se déplacent simplement selon les lois connues de la physique, ainsi que d'autres non encore découvertes mais quelque peu similaires, serait l'une des premières à disparaître.

Cet argument est à mon sens assez fort. On peut dire en réponse que de nombreuses théories scientifiques semblent rester réalisables dans la pratique, malgré leur conflit avec l'ESPÿ; qu'en fait on peut très bien s'entendre si on l'oublie. C'est un confort plutôt froid, et l'on craint que la pensée soit le genre de phénomène où l'ESP peut être particulièrement pertinente.

Un argument plus spécifique basé sur l'ESP pourrait être le suivant : « Jouons au jeu de l'imitation, en utilisant comme témoins un homme qui est bon comme récepteur télépathique, et un ordinateur numérique. L'interrogateur peut poser des questions telles que « À quelle couleur appartient la carte dans ma main droite ? L'homme par télépathie ou voyance donne la bonne réponse 130 fois sur 400 cartes. La machine ne peut que deviner au hasard, et obtient peut-être 104 bonnes réponses, de sorte que l'interrogateur fait la bonne identification. Il y a une possibilité intéressante qui s'ouvre ici. Supposons que l'ordinateur numérique contient un générateur de nombres aléatoires. Il sera alors naturel de s'en servir pour décider de la réponse à donner. Mais alors le générateur de nombres aléatoires sera soumis aux pouvoirs psycho-cinétiques de l'interrogateur. Peut-être que cette psychokinésie pourrait amener la machine à deviner juste plus souvent que ce à quoi on s'attendrait sur un calcul de probabilité, de sorte que l'interrogateur pourrait toujours être incapable de faire la bonne identification. D'un autre côté, il pourrait peut-être deviner

droit sans aucun questionnement, par voyance. Avec ESP, tout peut arriver.

Si la télépathie est admise, il faudra resserrer notre test. La situation pourrait être considérée comme analogue à celle qui se produirait si l'interrogateur parlait tout seul et si l'un des concurrents écoutait avec son oreille contre le mur. Placer les concurrents dans une « salle de télépathie » satisferait à toutes les exigences.

# 7. Machines d'apprentissage.

Le lecteur aura anticipé que je n'ai pas d'arguments très convaincants de nature positive pour étayer mes vues. Si je l'avais fait, je n'aurais pas pris tant de peine à souligner les erreurs des opinions contraires. Les preuves que j'ai, je vais maintenant les donner.

Revenons un instant à l'objection de Lady Lovelace, selon laquelle la machine ne peut faire que ce que nous lui disons de faire. On pourrait dire qu'un homme peut « injecter » une idée dans la machine, et que celle-ci répondra dans une certaine mesure puis tombera en repos, comme une corde de piano frappée par un marteau. Une autre comparaison serait un tas atomique de taille inférieure à la taille critique : une idée injectée correspondrait à un neutron entrant dans le tas de l'extérieur. Chacun de ces neutrons provoquera une certaine perturbation qui finira par disparaître. Si, cependant, la taille de la pile est suffisamment augmentée, la perturbation causée par un tel neutron entrant continuera très probablement à augmenter jusqu'à ce que la totalité de la pile soit détruite. Y a-t-il un phénomène correspondant pour les esprits, et y en a-t-il un pour les machines? Il semble y en avoir un pour l'esprit humain. La majorité d'entre eux semblent être « sous-critiques », c'est- à-dire correspondre dans cette analogie à des pieux de taille sous-critique. Une idée présentée à un tel esprit suscitera en moyenne moins d'une idée en réponse. Une petite proportion sont super-critiques. Une idée présentée à un tel esprit peut donner lieu à toute une « théorie » composée d'idées secondaires, tertiaires et plus lointaines. L'esprit des animaux semble très nettement souscritique. Adhérant à cette analogie, nous demandons : « Une machine peut-elle être conçue pour être super-critique ?

L'analogie avec la « peau d'un oignon » est également utile. En considérant les fonctions de l'esprit ou du cerveau, nous trouvons certaines opérations que nous pouvons expliquer en termes purement mécaniques. Ce que nous disons ne correspond pas à l'esprit réel : c'est une sorte de peau qu'il faut enlever si l'on veut trouver l'esprit réel. Mais ensuite, dans ce qui reste, nous trouvons une autre peau à enlever, et ainsi de suite. En procédent ainsi, arrivons-nous jamais à l'esprit "réel",

ou arrivons-nous finalement à la peau qui n'a rien dedans ? Dans ce dernier cas, tout l'esprit est mécanique. (Ce ne serait cependant pas une machine à états discrets. Nous en avons discuté.)

Ces deux derniers paragraphes ne prétendent pas être des arguments convaincants. Il faudrait plutôt les décrire comme des « récitations tendant à produire la croyance ».

Le seul appui vraiment satisfaisant que l'on puisse donner à l'opinion exprimée au début du § 6, sera celui fourni en attendant la fin du siècle et en faisant ensuite l'expérience décrite. Mais que dire en attendant ? Quelles mesures faut-il prendre maintenant pour que l'expérience réussisseÿ?

Comme je l'ai expliqué, le problème est principalement un problème de programmation. Des progrès en ingénierie devront également être réalisés, mais il semble peu probable qu'ils ne soient pas à la hauteur des besoins. Les estimations de la capacité de stockage du cerveau varient de 1010 à 1015 chiffres binaires. Je penche pour les valeurs inférieures et je crois que seule une très petite fraction est utilisée pour les types de pensée supérieurs. La majeure partie est probablement utilisée pour la rétention des impressions visuelles. Je serais surpris s'il fallait plus de 109 pour jouer de manière satisfaisante le jeu de l'imitation, en tout cas contre un aveugle.

(Remarque - La capacité de l' *Encyclopaedia Britannica*, 11e édition, est de 2 x 109 .) Une capacité de stockage de 107 serait une possibilité très pratique même avec les techniques actuelles. Il n'est probablement pas du tout nécessaire d'augmenter la vitesse de fonctionnement des machines. Les parties des machines modernes qui peuvent être considérées comme des analogues des cellules nerveuses fonctionnent environ mille fois plus vite que ces dernières. Cela devrait fournir une «marge de sécurité» qui pourrait couvrir les pertes de vitesse survenant de diverses manières. Notre problème est alors de savoir comment programmer ces machines pour jouer le jeu. À mon rythme de travail actuel, je produis environ un millier de chiffres de programme par jour, de sorte qu'une soixantaine de travailleurs, travaillant régulièrement au cours des cinquante années, pourraient accomplir le travail, si rien n'allait dans la corbeille à papier. Une méthode plus rapide semble souhaitable.

En essayant d'imiter un esprit humain adulte, nous sommes obligés de réfléchir beaucoup au processus qui l'a amené à l'état dans lequel il se trouve. Nous pouvons remarquer trois composants.

- (a) L'état initial de l'esprit, disons à la naissance,
- b) L'éducation à laquelle il a été soumis,
- (c) Autre expérience, ne pouvant être qualifiée d'éducation, à laquelle il a été soumis.

AM TURINGÜ:

Au lieu d'essayer de produire un programme pour simuler l'esprit d'un adulte, pourquoi ne pas plutôt essayer d'en produire un qui simule celui de l'enfant ? Si celuici était ensuite soumis à un enseignement approprié, on obtiendrait le cerveau adulte. Vraisemblablement, le cerveau de l'enfant est quelque chose comme un carnet de notes tel qu'on l'achète à la papeterie. Mécanisme assez peu, et beaucoup de feuilles vierges. (Mécanisme et écriture sont de notre point de vue presque synonymes.) Notre espoir est qu'il y a si peu de mécanisme dans le cerveau de l'enfant que quelque chose comme ça puisse être facilement programmé. Nous pouvons supposer, en première approximation, que la quantité de travail dans l'éducation est à peu près la même que pour l'enfant humain.

Nous avons donc divisé notre problème en deux parties. Le programme de l'enfant et le processus d'éducation. Ces deux-là restent très étroitement liés. Nous ne pouvons pas nous attendre à trouver une bonne machine-enfant du premier coup. Il faut expérimenter l'enseignement d'une telle machine et voir à quel point elle apprend. On peut alors en essayer un autre et voir si c'est mieux ou moins bien. Il y a un lien évident entre ce processus et l'évolution, par les identifications

Structure de la machine enfant = Matériel héréditaire

Changements , , = mutation

Sélection naturelle = Jugement de l'expérimentateur

On peut cependant espérer que ce processus sera plus rapide que l'évolution. La survie du plus apte est une méthode lente pour mesurer les avantages. L'expérimentateur, par l'exercice de l'intelligence, doit pouvoir l'accélérer. Tout aussi important est le fait qu'il n'est pas limité aux mutations aléatoires. S'il peut trouver une cause à une faiblesse, il peut

pensez probablement au genre de mutation qui l'améliorera.

Il ne sera pas possible d'appliquer exactement le même processus d'enseignement à la machine qu'à un enfant normal. Il ne sera pas, par exemple, pourvu de pieds, de sorte qu'on ne pourrait pas lui demander de sortir et de remplir le seau à charbon. Peut-être n'a-t-il pas d'yeux. Mais même si ces lacunes pouvaient être surmontées par une ingénierie intelligente, on ne pouvait pas envoyer la créature à l'école sans que les autres enfants s'en moquent excessivement. Il faut lui donner des cours. Il ne faut pas trop se préoccuper des jambes, des yeux, etc. L'exemple de MIIle Helen Keller montre que l'éducation peut avoir lieu à condition que la communication dans les deux sens entre maître et élève puisse avoir lieu par un moyen ou un autre.

Nous associons normalement les punitions et les récompenses au processus d'enseignement. Certaines machines-enfants simples peuvent être construites ou programmées sur ce genre de principe. La machine doit être construite de telle sorte que les événements qui ont précédé de peu l'apparition d'un signal de punition ne se reproduisent probablement pas, alors qu'un signal de récompense augmente la probabilité de répétition des événements qui y ont conduit. Ces définitions ne présupposent aucun sentiment de la part de la machine. J'ai fait quelques expériences avec une telle enfant-machine et j'ai réussi à lui enseigner quelques choses, mais la méthode d'enseignement était trop peu orthodoxe pour que l'expérience soit considérée comme vraiment réussie.

L'utilisation de punitions et de récompenses peut au mieux faire partie du processus d'enseignement. En gros, si l'enseignant n'a pas d'autre moyen de communication avec l'élève, la quantité d'informations qui peut lui parvenir ne dépasse pas le nombre total de récompenses et de punitions appliquées.

Au moment où un enfant a appris à répéter "Casabianca", il se sentirait probablement très mal, si le texte ne pouvait être découvert que par une technique de "Vingt questions", chaque "NON" prenant la forme d'un coup. Il est donc nécessaire d'avoir d'autres canaux de communication « sans émotion ». Si

ceux-ci sont disponibles, il est possible d'apprendre à une machine par des punitions et des récompenses à obéir à des ordres donnés dans un certain langage, par exemple un langage symbolique. Ces ordres doivent être transmis par les canaux « sans émotion ». L'utilisation de ce langage diminuera considérablement le nombre de punitions et de récompenses requises.

Les opinions peuvent varier quant à la complexité qui convient à la machine enfant. On pourrait essayer de le rendre aussi simple que possible conformément aux principes généraux. Alternativement, on pourrait avoir un système complet d'inférence logique «intégré».

<sup>1</sup> Dans ce dernier cas, le magasin serait en grande partie occupée de définitions et de propositions. Les propositions auraient divers statuts, *par exemple* des faits bien établis, des conjectures, des théorèmes mathématiquement prouvés, des déclarations données par une autorité, des expressions ayant la forme logique de proposition mais pas de valeur de croyance.

Certaines propositions peuvent être qualifiées d'« impératifs ». La machine doit être construite de telle sorte que dès qu'un impératif est classé comme "bien établi", l'action appropriée se produit automatiquement. Pour illustrer cela, supposons que l'enseignant dise à la machine : « Faites vos devoirs maintenant ».

Cela peut entraîner l'inclusion de "Le professeur dit 'Fais tes devoirs maintenant"

<sup>1</sup> Ou plutôt "programmé en" car notre enfant-machine sera programmé en un ordinateur numérique. Mais le système logique n'aura pas à être appris.

parmi les faits bien établis. Un autre fait pourrait être,

"Tout ce que dit le professeur est vrai". La combinaison de ceux-ci peut éventuellement conduire à l'impératif, "Faites vos devoirs maintenant", étant inclus parmi les faits bien établis, et cela, par la construction de la machine, signifiera que les devoirs commencent réellement, mais l'effet est très satisfaisant . Les processus d'inférence utilisés par la machine n'ont pas besoin d'être de nature à satisfaire les logiciens les plus exigeants. Il pourrait par exemple n'y avoir aucune hiérarchie de types. Mais cela ne signifie pas nécessairement que des erreurs de type se produiront, pas plus que nous ne sommes condamnés à tomber par-dessus des falaises non clôturées. Des impératifs appropriés (exprimés *au sein* des systèmes, ne faisant pas partie des règles *de* système) telles que "N'utilisez pas une classe à moins qu'il ne s'agisse d'une sous-classe de celle qui a été mentionnée par l'enseignant" peut avoir un effet similaire à "Ne vous approchez pas trop du bord".

Les impératifs auxquels peut obéir une machine qui n'a pas de membres sont forcément d'un caractère plutôt intellectuel, comme dans l'exemple (faire ses devoirs) donné ci-dessus. Parmi ces impératifs, les plus importants seront ceux qui règlent l'ordre dans lequel les règles du système logique concerné doivent être appliquées. Car à chaque étape où l'on utilise un système logique, il y a un très grand nombre d'étapes alternatives, dont chacune est autorisée à appliquer, en ce qui concerne l'obéissance aux règles du système logique.

Ces choix font la différence entre un raisonneur brillant et un raisonnable, pas la différence entre un bon et un faux.

Les propositions conduisant à des impératifs de ce type pourraient être "Quand Socrate est mentionné, utilisez le syllogisme de Barbara" ou "Si une méthode s'est avérée plus rapide qu'une autre, n'utilisez pas la méthode la plus lente". Certains d'entre eux peuvent être « donnés par autorité », mais d'autres peuvent être produits par la machine elle-même, par exemple par induction scientifique.

L'idée d'une machine apprenante peut sembler paradoxale à certains lecteurs. Comment les règles de fonctionnement de la machine peuvent-elles changer ? Ils doivent décrire complètement comment la machine réagira quel que soit son historique, quels que soient les changements qu'elle pourrait subir. Les règles sont donc assez invariantes dans le temps. C'est tout à fait vrai. L'explication du paradoxe est que les règles qui sont modifiées dans le processus d'apprentissage sont d'un genre plutôt moins prétentieux, ne revendiquant qu'une validité éphémère. Le lecteur peut établir un parallèle avec la Constitution des États-Unis.

Une caractéristique importante d'une machine à apprendre est que son enseignant sera souvent très largement ignorant de ce qui se passe à l'intérieur, bien qu'il puisse toujours être capable, dans une certaine mesure, de prédire le comportement de son élève. Cela devrait s'appliquer plus fortement à l'éducation ultérieure d'une machine issue d'un enfant

machine de conception (ou programme) éprouvée. Ceci est en contraste clair avec la procédure normale lors de l'utilisation d'une machine pour faire des calculs : l'objectif est alors d'avoir une image mentale claire de l'état de la machine à chaque instant du calcul. Cet objectif ne peut être atteint qu'au prix d'une lutte. L'idée que "la machine ne peut faire que ce que nous savons lui ordonner de faire".

1 semble étrange face à cela. La plupart des programmes que nous pouvons mettre dans la machine aura pour résultat qu'elle fera quelque chose que nous ne pouvons pas comprendre du tout, ou que nous considérons comme un comportement complètement aléatoire. Le comportement intelligent consiste vraisemblablement en un écart par rapport au comportement complètement discipliné impliqué dans le calcul, mais plutôt léger, qui ne donne pas lieu à un comportement aléatoire, ou à des boucles répétitives inutiles. Un autre résultat important de la préparation de notre machine à son rôle dans le jeu de l'imitation par un processus d'enseignement et d'apprentissage est que la « faillibilité humaine » est susceptible d'être omise d'une manière assez naturelle, c'est-à- dire sans "coaching" particulier. (Le lecteur doit réconcilier cela avec le point de vue des pp. 24, 25.) Les processus qui sont appris ne produisent pas cent pour cent. certitude du résultat; s'ils le faisaient, ils ne pourraient pas être désappris.

Il est probablement judicieux d'inclure un élément aléatoire dans une machine d'apprentissage (voir p. 438). Un élément aléatoire est plutôt utile lorsque nous recherchons une solution à un problème. Supposons par exemple que nous voulions trouver un nombre entre 50 et 200 égal au carré de la somme de ses chiffres, nous pourrions commencer à 51 puis essayer 52 et continuer jusqu'à ce que nous obtenions un nombre qui fonctionne. Alternativement, nous pourrions choisir des numéros au hasard jusqu'à ce que nous en ayons un bon. Cette méthode a l'avantage qu'il n'est pas nécessaire de garder une trace des valeurs qui ont été essayées, mais l'inconvénient qu'on peut essayer deux fois la même, mais ce n'est pas très important s'il y a plusieurs solutions. La méthode systématique a l'inconvénient qu'il peut y avoir un énorme bloc sans aucune solution dans la région qui doit être étudiée en premier. Or, le processus d'apprentissage peut être considéré comme une recherche d'un comportement qui satisfasse le maître (ou un autre critère). Puisqu'il existe probablement un très grand nombre de solutions satisfaisantes, la méthode aléatoire semble être meilleure que la méthode systématique. Il faut remarquer qu'il est utilisé dans le processus analogue d'évolution. Mais là, la méthode systématique n'est pas possible. Comment pourrait-on suivre

<sup>&</sup>lt;sup>1</sup> Comparez la déclaration de Lady Lovelace (p. 450), qui ne contient pas le mot 'seulement'.

AM TURINGÜ:

460

les différentes combinaisons génétiques qui avaient été essayées, pour éviter de les réessayer?

On peut espérer que les machines finiront par concurrencer les hommes dans tous les domaines purement intellectuels. Mais quels sont les meilleurs pour commencer ? C'est même une décision difficile. Beaucoup de gens pensent qu'une activité très abstraite, comme jouer aux échecs, serait la meilleure. On peut également soutenir qu'il est préférable de doter la machine des meilleurs organes sensoriels que l'argent puisse acheter, puis de lui apprendre à comprendre et à parler anglais. Ce processus pourrait suivre l'enseignement normal d'un enfant. Les choses seraient signalées et nommées, etc. Encore une fois, je ne sais pas quelle est la bonne réponse, mais je pense que les deux approches devraient être essayées.

Nous ne pouvons voir qu'une courte distance devant nous, mais nous pouvons voir beaucoup de choses à faire.

# **BIBLIOGRAPHIE**

Samuel Butler, Erewhon, Londres, 1865. Chapitres 23, 24, 25, Le Livre des Machines.

- Alonzo Church, "Un problème insoluble de la théorie élémentaire des nombres", *American J. of Math.*, 58 (1936), 345-363.
- K. Gödel, « Über formal unentscheildbare Sätze der Principia Mathematica und verwandter Systeme, I", Monatshefle für Math, und Phys., (1931), 173-189.
- DR Hartree, Calculating Instruments and Machines, New York, 1949.
- SC Kleene, "Fonctions récursives générales des nombres naturels", *American J. of Math.*, 57 (1935), 153-173 et 219-244.
- G. Jefferson, "L'esprit de l'homme mécanique". Discours de Lister pour 1949. *Journal médical britannique*, vol. i (1949), 1105-1121.
- Comtesse de Lovelace, «Notes du traducteur à un article sur l'Engiro analytique de Babbage», *Mémoires scientifiques* (éd. Par R. Taylor), vol. 3 (1842), 691-731.

Bertrand Russell, History of Western Philosophy, Londres, 1940.

AM Turing, "Sur les nombres calculables, avec une application au problème d'Entscheidungsproblem", *Proc. Mathématiques de Londres. Soc.* (2), 42 (1937), 230-265.

Université Victoria de Manchester.